

규칙 기반 조건 추출과 속성 재랭킹을 결합한 한국어 자연어 음식 메뉴 추천

먹지(Muckzi) 프로젝트 기술 보고서 · 2026-09-26

초록

사람들은 메뉴를 고를 때 "비도 오고 쌀쌀한데 얼큰한 국물 먹고 싶어"처럼 맛, 온도, 날씨를 한 문장에 섞어 말한다. 본 연구는 이런 한국어 문장을 받아 음식 메뉴 상위 $K = 5$ 개를 추천하는 시스템을 만들고, 그 과정에서 문장 임베딩 검색만으로는 해결되지 않는 문제가 무엇인지 살폈다.

데이터는 공공데이터포털의 식품 영양성분 데이터 19,617행을 식사 메뉴 단위로 정제해 5,219건을 만들고, 대규모 언어 모델로 매운맛, 국물, 제공온도, 조리법, 기름짐, 든든함의 여섯 가지 속성을 붙였다. 추천 후보는 업체명이 없는 공공 데이터 1,088건이다. 제안하는 방법은 정규식 규칙 43개로 문장을 필수 조건, 선호 조건, 메뉴 언급, 메뉴 제외, 맥락으로 나눈 뒤, multilingual-e5-base로 찾은 후보를 필수 조건으로 거르고 유사도, 선호 일치율, 가점의 선형 결합으로 다시 정렬한다. 같은 메뉴군이 결과를 독차지하지 않도록 메뉴군마다 상한도 둔다.

점수의 척도를 들여다보면 후보 100개 안에서 유사도 향이 움직이는 폭은 평균 0.014에 불과하다. 선호 조건 한 단계의 차이(최소 0.1)보다 한 자릿수 작으므로 재랭킹은 사실상 선호 일치율을 먼저 보는 사전식 정렬처럼 동작한다. 본 연구는 이 관계에서 가점 크기가 넘지 말아야 할 상한을 유도했고, 실험에서 성능이 바뀌는 지점이 그 상한과 맞는 것을 확인했다.

질의 36개와 승인된 적합도 판정 906건(교차 판정 가중 $\kappa_w = 0.919$)으로 평가한 결과, 임베딩만 쓴 기준선의 nDCG@5 0.509가 0.878(P@5 0.789, MRR 0.938)로 올랐다. 향상 폭 +0.369의 95% 부트스트랩 신뢰구간은 [+0.244, +0.495]이다. 향상은 부정 표현 질의에서 가장 컸고(0.173에서 0.893), 기성 cross-encoder 재정렬(bge-reranker-v2-m3)을 조건 로직 위에 더해도 성능은 오르지 않았다. 다만 평가 질의를 보면서 시스템을 조정했으므로 처음 보는 질의에서는 성능이 이보다 낮을 가능성이 크다.

시스템을 웹 서비스에 붙인 뒤에는 사용자 반응을 질의 단어와 메뉴 조합별 가점으로 바로 반영하고, 승인 판정 295쌍으로 인코더를 미세조정해 보았다. 학습에 쓴 질의의 정답 회수율@10은 0.405에서 0.518로 올랐지만, 학습에 쓰지 않은 질의 10개에서는 0.439에서 0.405로 내려가 일반화되지 않았다. 미판정을 0점으로 두는 nDCG가 0.932에서 0.740으로 크게 떨어진 것도 대부분 풀링 편향 때문이었다. 그래서 condensed nDCG와 회수율로 모델 교체 기준을 세우고 서비스에는 기본 모델을 유지했다.

주제어 자연어 추천, 조건 기반 검색, 밀집 검색, 재랭킹, 부정 표현, 풀링 평가, 사용자 피드백, 미세조정

1. 서론

1.1 배경

점심 메뉴를 정하지 못해 동료에게 "뭐 먹을래?"라고 물으면 돌아오는 답은 대개 메뉴 이름이 아니다. "안 맵고 국물 있는 거", "튀김 말고 가벼운 거", "비 오니까 따뜻한 거"처럼 원하는 속성과 원하지 않는 속성을 섞어서 말한다. 이런 요청은 속성에 대한 제약과 선호의 조합이다. 과거 이력에서 취향을 추정하는 협업 필터링보다는 문장 자체를 해석하는 방식이 더 잘 맞는다.

문장 임베딩을 이용한 밀집 검색은 의미가 가까운 문서를 잘 찾지만, 논리적 조건을 지키는 데는 약하다. 대조 학습으로 훈련한 임베딩에게 "맵지 않은 음식"과 "매운 음식"은 같은 주제어를 공유하는 가까운 문장이다. 본 연구의 평가에서도 부정 표현이 들어간 질의에 임베딩만 쓰면 nDCG@5가 0.173에 머물렀다(7.2절). 매운 것을 싫다고 한 사용자에게 매운탕을 1위로 추천하는 시스템은 다른 질의에서 아무리 잘해도 믿기 어렵다.

1.2 접근 방식

본 연구는 문제를 두 부분으로 나누었다. 문장에서 조건을 뽑아내는 일은 규칙이 말고, 조건으로 설명되지 않는 의미의 가까움은 임베딩이 맡는다. 그림 1은 전체 구조를 보여 준다. 왼쪽 열은 한 번만 만들어 두는 메뉴 인덱스이고, 오른쪽 열은 질의가 들어올 때마다 실행되는 처리 과정이다.




그림 1 시스템 전체 구조. 왼쪽은 공공 음식 데이터를 정제하고 속성을 붙여 후보 벡터로 만드는 오프라인 과정이다. 오른쪽은 사용자 문장을 임베딩과 조건 추출로 나눠 처리한 뒤 검색, 필터, 재랭킹, 다양성 제어, 피드백 가점을 거쳐 상위 K 개를 내는 과정이다. 회색 상자 안에서는 후보가 부족할 때 검색 범위 k 를 두 배씩 넓혀 다시 수행한다.

이 구조에서 임베딩 검색은 후보를 넓게 모으는 역할만 한다. 순위의 큰 틀은 조건 추출기가 뽑은 필수 조건과 선호 조건이 정한다. 처음에는 임베딩 점수와 조건 점수를 적당히 섞으면 된다고 생각했지만, 점수의 척도를 재 보니 두 점수는 섞이는 것이 아니라 한쪽이 다른 쪽을 거의 완전히 지배했다. 5.6절에서 이 관계를 정리하고, 그 결과를 가중치 설계에 그대로 이용했다.

1.3 연구 질문

- **RQ1** 규칙 기반 조건 추출과 속성 필터, 재랭킹은 밀집 검색에 비해 얼마나 기여하는가
- **RQ2** 유사도, 선호, 가점을 선형 결합할 때 각 항의 척도는 순위에 어떤 영향을 주며, 가중치는 어떤 조건을 만족해야 하는가
- **RQ3** 범용 cross-encoder 재정렬이나 대분류 우선 추천 같은 대안은 이 도메인에서 효과가 있는가

- RQ4 모델 판정으로 만든 평가 세트는 얼마나 믿을 만하며, 결과 해석의 한계는 무엇인가
- RQ5 사용자 피드백과 판정 데이터로 인코더를 미세조정하면 처음 보는 질의에서도 나아지는가, 그리고 기존 판정 풀로 이를 공정하게 잴 수 있는가

1.4 기여

첫째, 공공 영양성분 데이터를 식사 메뉴 단위로 정제하고 여섯 가지 속성 라벨을 붙인 한국어 메뉴 후보 집합을 만들었다. 둘째, 필수와 선택을 구분하고 거부어에 따른 극성 반전, 강조어에 따른 승격, 조건 병합과 모순 검출을 포함하는 조건 추출 규칙을 형식화했다. 셋째, 재랭킹 점수의 척도를 분석해 가점 크기의 상한 조건을 유도하고 실험으로 확인했다. 넷째, 여러 설정의 상위 결과를 합쳐 두 모델이 교차 판정한 풀링 판정 세트를 만들고 일치도를 보고했다. 다섯째, cross-encoder 재정렬과 대분류 우선 추천이 이 데이터에서 효과가 없는 이유를 수치로 제시했다. 마지막으로 사용자 피드백 가점과 판정 기반 미세조정을 실제 서비스에 붙이고, 풀링 편향을 피하는 교체 기준으로 미세조정 효과를 검증했다.

1.5 보고서 구성

2장에서 관련 연구를 정리하고 3장에서 문제를 정의한다. 4장은 데이터 구축 과정, 5장은 조건 추출부터 검색 범위 확장까지의 방법을 다룬다. 6장과 7장은 실험 설정과 결과이며, 8장은 서비스 연동과 피드백 학습, 9장부터 11장은 논의, 한계, 결론이다.

2. 관련 연구

2.1 밀집 검색

Sentence-BERT(Reimers & Gurevych, 2019) 이후 문장 임베딩의 코사인 유사도로 문서를 찾는 bi-encoder 방식이 널리 쓰인다. 질의와 문서를 따로 인코딩하므로 문서 벡터를 미리 계산해 둘 수 있고, 검색은 내적 몇 번으로 끝난다. E5(Wang et al., 2024)는 대규모 약지도 쌍으로 대조 학습한 텍스트 임베딩 모델로, 질의와 문서에 각각 query:, passage: 접두어를 붙여 비대칭 검색을 한다. 본 연구는 그 다국어판인 multilingual-e5-base를 쓴다.

2.2 재정렬

cross-encoder는 질의와 문서를 한 입력으로 넣어 토큰 사이의 상호작용을 직접 모델링하므로 대체로 bi-encoder보다 정확하다. 계산 비용이 커서 보통 bi-encoder가 찾은 상위 후보만 다시 매기는 2단계 구조로 쓴다(Nogueira & Cho, 2019). BGE M3(Chen et al., 2024) 계열의 재정렬 모델은 한국어를 포함한 다국어를 지원하므로, 본 연구는 이를 대안으로 시험했다(7.5절).

2.3 조건 기반 추천

지식 기반 또는 제약 기반 추천은 사용자가 명시한 속성 제약을 만족하는 항목을 고른다. 이 분야에서 오래된 질문은 제약을 모두 만족하는 항목이 없을 때 어떤 제약을 풀어 줄 것인가이다(Felfernig & Burke, 2008). 본 연구는 필수

조건을 풀지 않는 쪽을 택했다. 대신 검색 범위를 넓히고, 그래도 부족하면 사유와 함께 적게 반환한다. 선호 조건은 점수에만 반영한다.

2.4 평가 방법

순위 지표로는 누적 이득 기반의 nDCG(Järvelin & Kekäläinen, 2002), P@K, MRR을 쓴다. 모든 문서를 판정할 수 없을 때는 여러 시스템의 상위 결과만 모아 판정하는 TREC 방식의 폴링을 쓴다. 이때 풀에 없는 문서를 부적합으로 보는 가정이 풀을 만들 때 없던 새로운 시스템에 불리하게 작용한다는 편향이 알려져 있다(Buckley & Voorhees, 2004). 8장의 미세조정 실험은 정확히 이 문제에 부딪혔고, 미판정 항목을 지우고 순위를 매기는 condensed 지표(Sakai, 2007)로 해결했다. 판정자 사이의 일치도는 Cohen의 κ 로 보고한다(Cohen, 1960).

3. 문제 정의

후보 메뉴 집합을 $\mathcal{D}(|\mathcal{D}| = 1,088)$, 속성 집합을 $\mathcal{A}(|\mathcal{A}| = 6)$, 속성 a 의 값 영역을 V_a 라 하자. 라벨을 정할 수 없는 경우는 $\perp$ (미확인)로 둔다. 각 메뉴 d 는 라벨 벡터

$$\ell(d) = (\ell_a(d))_{a \in \mathcal{A}}, \quad \ell_a(d) \in V_a \cup \{\perp\}$$

와 메뉴명, 대표식품명, 식품대분류명으로 이루어진 이름 정보 $n(d)$ 를 가진다. 질의 q 가 주어지면 시스템은 순서가 있는 목록 $R_q = (d_1, \dots, d_k)$, $k \leq K$ 를 돌려주며, 목표는 적합도 판정 $g(q, d) \in \{0, 1, 2\}$ 에 대한 순위 지표를 최대화하는 것이다.

조건 추출기 π 는 질의를 다섯 요소로 나눈다.

$$\pi(q) = (H, S, M, X, C)$$

$H = \{(a, A_a^H)\}$ 는 필수 조건이고 $A_a^H \subseteq V_a$ 는 허용값 집합이다. $S = \{(a, A_a^S)\}$ 는 선호 조건, M 은 사용자가 언급한 메뉴 용어의 집합(예: "샌드위치"), X 는 제외한 메뉴 용어의 집합(예: "피자 말고"의 "피자"), C 는 맥락이 연상하게 하는 메뉴 용어의 집합(예: "비 오는 날"의 "칼국수")이다.

메뉴 d 가 용어 t 를 가리키는지는 부분 문자열이 아니라 완전 일치로 판정한다.

$$\mu(d, t) = 1[t = \text{대표식품명}(d) \vee t \in \text{tok}(\text{메뉴명}(d)) \vee t \in \text{tok}(\text{대분류}(d))]$$

tok은 공백 기준 어절 집합이다. 부분 문자열로 대조하면 "무조건 안 매운 길로"의 "무"가 "무국"과 맞아 버리므로 어절 단위 완전 일치를 쓴다.

4. 데이터

4.1 원본과 정제

원본은 공공데이터포털의 식품 영양성분 데이터(food_nutrition.csv, 19,617행, 50열)이다. 영양성분 데이터이므로 반찬, 음료, 가공식품까지 섞여 있고, 같은 메뉴가 중량이나 업체만 달리해 여러 번 나온다. 그림 2는 이를 추천 후보로 줄여 가는 과정이다.




그림 2 데이터 구축 과정. 아래 줄은 원본에서 추천 후보까지 행 수가 줄어드는 단계이고, 위 줄은 라벨링 단위에 속성을 붙이는 과정이다. 라벨이 스키마 검증을 통과하지 못하면 다시 라벨링한다.

단계	건수	처리
원본	19,617	식품 영양성분 DB
정제	18,998	이름 정리, 중량 분리, 컬럼 선별
식사 메뉴	8,032	식품대분류로 식사를 고르고 반찬, 디저트, 음료 제외. 빵 및 과자류 중 피자, 버거, 샌드위치 등은 식사로 포함
라벨링 단위	5,219	같은 메뉴의 중복 행 통합
공공 데이터 (업체명 없음)	1,123	프랜차이즈 메뉴 제외
추천 후보 $\mathcal{D}$	1,088	쌀밥, 잡곡밥 같은 맨밥 제외

후보는 식품대분류 12개에 퍼져 있다. 국 및 탕류(210), 찌개 및 전골류(153), 밥류(151), 면 및 만두류(129), 구이류(98), 볶음류(88) 순으로 많다.

프랜차이즈 메뉴를 뺀 데에는 두 가지 이유가 있다. 하나는 같은 메뉴의 브랜드별 변형이 상위를 독점하는 문제이고, 다른 하나는 데이터 출처의 일관성이다. 맨밥은 "밥"을 단독으로 말한 질의를 밥류 전체에 대한 요청으로 해석하기 위해 뺐다. 그대로 두면 쌀밥과 잡곡밥이 밥 요리보다 앞에 올 수 있다.

4.2 속성 라벨

속성 a	값 영역 V_a	$ V_a $
매운맛	없음, 약함, 보통, 강함	4
국물	국물요리, 국물약간, 국물없음	3
제공온도	뜨거움, 따뜻함, 상온, 차가움	4
조리법	끓임, 볶음, 구이, 튀김, 찜, 조림, 부침, 오븐, 비조리, 혼합	10
기름짐	낮음, 보통, 높음	3
든든함	가벼움, 보통, 든든함	3

단맛, 신맛, 고소함처럼 사람들이 자주 쓰는 맛 표현 중에는 이 스키마에 없는 축도 있다. 이 공백은 7.7절의 오류 분석에서 한계로 드러난다.

라벨은 이름 정보 $n(d)$ 만 입력으로 대화형 언어 모델 세션에서 매겼다(유료 API는 쓰지 않았다). 모델의 출력은 스키마 검증을 거친다. 값 영역 밖의 값이나 형식 오류가 있으면 그 항목만 다시 매겼고, 원본에 온도 표기(HOT, ICED)가 있으면 그와 양립하는 제공온도만 허용했다. 라벨링 지시문에는 판단 근거가 부족하면 추측으로 채우지 말고 $\perp$ 으로 두라고 적었다.

4.3 계열과 안주

원본에는 음식의 나라별 계열이나 술안주 여부가 없다. 하지만 "한식 위주로", "중식 말고", "안주로 먹을 거" 같은 요청이 흔하고, 서비스에서 음식점을 찾을 때도 계열이 필요하다(8.1절). 그래서 계열(한식, 중식, 일식, 양식, 동남아, 분식)과 안주 여부를 메뉴명 키워드 규칙으로 먼저 추정하고, 공공 데이터 1,123건은 대화 모델이 매긴 값으로 보정했다. 보정 라벨이 있으면 그 값을 우선한다.

4.4 라벨의 빈칸




그림 3 속성별 미확인($\perp$) 비율.

그림 3에서 속성별 $\perp$ 비율은 든든함이 23.3%로 가장 높고 매운맛이 5.1%, 나머지는 1% 미만이다. 든든함은 메뉴 이름만으로는 양을 알 수 없는 경우가 많아서 비율이 높게 나왔다. 5.4절의 필터는 $\perp$ 을 조건 충족으로 보지 않으므로, 든든함이 필수 조건이 되면 후보 넷 중 하나가 무조건 빠진다. 라벨은 모두 모델 추정이며 사람이 표본을 검토한 정확도는 아직 재지 않았다(10.3절).

5. 방법

5.1 처리 흐름

그림 1의 오른쪽 열을 순서대로 따라가면 다음과 같다. 질의 q 가 들어오면 조건 추출기 π 와 인코더 f 가 각각 실행된다. 인코더의 결과로 코사인 유사도 상위 k 개 후보를 찾고, 필수 조건과 제외 메뉴로 거른 다음, 선호 조건과 가점으로 점수를 매겨 정렬한다. 정렬된 목록에서 변형과 같은 메뉴군을 정리하며 K 개를 고르고, 모자라면 k 를 넓혀 다시 수행한다. 마지막으로 서비스에서는 사용자 피드백 가점을 더한다(8.2절). 아래에서 각 단계를 자세히 설명한다.

5.2 조건 추출

조건 추출기는 그림 4처럼 다섯 단계로 이루어진다. 아래 세 줄은 실제 질의가 각 단계를 지나며 바뀌는 모습이다.




그림 4 조건 추출기의 구조와 처리 예. 첫 번째 예는 거부어에 의한 극성 반전, 두 번째 예는 선호와 맥락이 함께 있는 일반적인 질의, 세 번째 예는 모순 검출이다.

규칙 매칭 규칙 집합 $\mathcal{R}$ 은 정규식 43개로 이루어진다. 각 규칙 r 은 패턴, 종류 $\tau(r) \in \{\text{hard}, \text{soft}, \text{context}, \text{unhandled}\}$, 조건 목록 $\{(a, A)\}$ 를 가진다. 규칙은 우선순위 순서로 적용되고, 먼저 매칭된 구간과 겹치는 매칭은 버린다. 부정형 규칙("맵지 않은")을 긍정형 규칙("매운")보다 앞에 두었기 때문에, "맵지 않은"이 매칭된 자리에서 "매운"이 다시 매칭되는 일은 없다.

종류	개수	예	처리
hard	7	"맵지 않은", "국물 없는", "튀김 말고"	H 에 추가
soft	26	"얼큰한", "따뜻한", "가볍게", "한식 위주로"	S 에 추가
context	6	"비 오는 날", "추운 날", "야식"	연상 용어를 C 에 추가
unhandled	4	이중 부정, "단짠", "상큼", "시원한 국물"	조건 없이 기록만

hard 규칙에는 거부 표현이 규칙 안에 들어 있다. 예를 들어 "매운 거 싫어"는 매운맛 제외 규칙이 바로 잡아 (매운맛, {없음})이 된다. "너무 맵지 않은"처럼 정도를 누그러뜨린 표현은 따로 규칙을 두어 (매운맛, {없음, 약함, 보통})으로 처리한다.

soft 규칙 하나가 조건 여러 개를 만들기도 한다. "얼큰한"은 매운맛 {보통, 강함}과 제공온도 {뜨거움, 따뜻함}을 함께 만들고, "담백한"은 기름짐 {낮음}과 매운맛 {없음, 약함}을 만든다.

context 규칙은 필수 조건을 만들지 않는다. 비 오는 날에 꼭 전을 먹어야 하는 것은 아니기 때문이다. 대신 연상되는 메뉴 용어를 C 에 넣어 작은 가점만 준다. 비는 전, 칼국수, 수제비를, 추운 날은 국과 찌개를, 더운 날은 냉면, 냉국, 콩국수를 연상한다. 기분이나 시간대("피곤할 때", "야식")는 연상 메뉴 없이 기록만 하고 임베딩 유사도에 맡긴다.

unhandled 규칙은 처리하지 못한다는 사실을 명시적으로 남기기 위해 두었다. "시원한 국물"의 "시원한"은 차가운 온도가 아니라 해장이 되는 맛을 뜻하는 경우가 많아 온도 조건으로 확정하지 않는다. "안 매운 건 싫어" 같은 이중 부정은 방향을 확정하지 않는다.

극성 처리 soft 규칙이 매칭된 직후에 거부어 패턴 ρ ("싫", "빠", "말고", "못 먹", "아닌", "별로" 등)가 이어지면 조건을 여집합의 필수 조건으로 바꾼다.

$$(a, A) \in S \text{ 이고 } \rho \text{ 가 뒤따르면 } (a, V_a \setminus A) \in H$$

"얼큰한 건 싫어"는 이 경로를 탄다. "얼큰"은 선호 규칙이지만 뒤에 "싫"이 붙어 매운맛의 여집합 {없음, 약함}이 필수 조건이 된다. 이때 규칙이 만든 조건 중 첫 번째만 뒤집는다. "얼큰한 건 싫어"를 뜨거운 음식까지 싫다는 뜻으로 보기는 어렵기 때문이다. "튀긴 거 빼고"도 같은 방식으로 조리법에서 튀김만 뺀 아홉 가지 값을 필수 허용값으로 가진다.

반대로 "꼭", "반드시", "무조건"이 매칭 바로 앞에 있으면 선호를 같은 허용값의 필수 조건으로 올린다. "꼭 국물 요리로"는 국물 {국물 요리}가 선호가 아닌 필수 조건이 된다.

병합과 모순 검출 같은 속성의 필수 조건 $A_a^{(1)}, \dots, A_a^{(m)}$ 는 교집합으로 합친다.

$$A_a^H = \bigcap_{i=1}^m A_a^{(i)}, \quad A_a^H = \emptyset \Rightarrow \text{모순}$$

같은 속성에 선호 조건이 함께 있으면 선호의 허용값을 필수 허용값 안으로 좁히고, 겹치는 값이 하나도 없으면 역시 모순으로 본다. "맵지 않은 매운 음식"은 필수 {없음}과 선호 {보통, 강함}이 겹치지 않으므로 모순이다. 이때는 억지로 추천하지 않고 "맵지 않은 vs 매운"이라는 사유를 돌려준다.

메뉴 언급과 제외 메뉴 용어("피자", "국밥", "면" 등)는 조건 규칙과 별도로 찾는다. 바로 뒤에 "말고", "빼고", "아닌" 같은 표현이 오면 X 에, 그렇지 않으면 M 에 넣는다. "피자 말고 버거"는 $X = \{\text{피자}\}$, $M = \{\text{버거}\}$ 가 된다. "밥"을 단독으로 말하면 밥류 언급이면서 한식 선호로 해석한다.

5.3 메뉴 텍스트와 검색

질의와 메뉴 텍스트는 같은 인코더로 임베딩한다. 메뉴 쪽 텍스트는 두 가지로 만들어 비교했다. 텍스트 A 는 메뉴명, 대표식품명, 식품대분류명을 이어 붙인 문자열이고, 텍스트 B 는 그 뒤에 $\perp$ 이 아닌 속성 값을 토큰으로 덧붙인 문자열이다. 예를 들어 소고기스튜의 텍스트 B 는 "소고기스튜 찜류 매운맛 없음 국물약간 제공온도 뜨거움 ..."처럼 된다.

인코더는 mean pooling 뒤 L2 정규화를 하므로 코사인 유사도는 내적과 같다.

$$s(q, d) = \langle f(\text{query: } q), f(\text{passage: text}(d)) \rangle, \quad \|f(\cdot)\|_2 = 1$$

메뉴 벡터는 미리 계산해 저장해 둔다. 저장할 때 모델 리비전, 접두어, pooling 방식, 원본 파일 해시를 manifest에 함께 기록하고, 불러올 때 현재 설정과 하나라도 다르면 쓰지 않는다. 텍스트 구성이나 모델을 바꾼 뒤 예전 벡터를 그대로 쓰는 실수를 막기 위한 장치다.

5.4 필터

상위 k 개 후보 집합을 $C_k(q)$ 라 하면 필터를 통과한 후보는

$$\mathcal{F}_k(q) = \left\{ d \in C_k(q) : \forall (a, A) \in H, \ell_a(d) \in A \wedge \forall t \in X, \mu(d, t) = 0 \right\}$$

이다. $\perp \notin A$ 이므로 라벨이 $\perp$ 인 메뉴는 그 속성의 필수 조건을 충족하지 못한다. 매운지 모르는 메뉴를 "안 매운 음식"으로 내보내는 것보다 빼는 편이 안전하다고 판단했다.

5.5 재랭킹 점수

선호 일치율 p 와 가점 b 는 다음과 같다.

$$p(q, d) = \begin{cases} \frac{1}{|S|} \sum_{(a, A) \in S} 1[\ell_a(d) \in A] & |S| > 0 \\ 0 & |S| = 0 \end{cases}$$

$$b(q, d) = \max \left(w_m \cdot \max_{t \in M} \mu(d, t), w_c \cdot \max_{t \in C} \mu(d, t) \right)$$

최종 점수는 세 항의 선형 결합이다.

$$\text{score}(q, d) = w_s \cdot s(q, d) + w_p \cdot p(q, d) + b(q, d)$$

기본값은 $w_s = 0.7$, $w_p = 0.3$, $w_m = 0.3$, $w_c = 0.05$ 이다. 동점은 유사도 내림차순, 메뉴 ID 오름차순으로 깨서 같은 입력에는 늘 같은 결과가 나오게 했다. p 에서도 $\perp$ 은 일치로 세지 않으므로 라벨이 빈 메뉴는 선호 조건에서 불리하다. 두 가점을 더하지 않고 큰 쪽만 쓰는 것은 언급 메뉴와 연상 메뉴가 겹칠 때 이중으로 가산되는 것을 막기 위해서다.

5.6 점수 척도 분석

가중치 $w_s = 0.7$ 은 유사도가 점수의 70%를 차지한다는 인상을 준다. 실제로 그런지 확인하려고 후보 $C_{100}(q)$ 안에서 유사도가 움직이는 폭을 잴다.

$$\Delta_s(q) = \max_{d \in C_{100}(q)} s(q, d) - \min_{d \in C_{100}(q)} s(q, d)$$




그림 5 평가 질의별 후보 100개 안의 유사도 폭 $w_s\Delta_s$ 와 선호 조건 한 단계의 점수 차이 $w_p/|S|$.

평가 질의 36개에서 1위 유사도의 평균은 0.844, Δ_s 의 평균은 0.0196, 최댓값은 0.052였다. 상위 100개의 유사도가 0.8 안팎의 좁은 띠에 몰려 있는 것이다. 그림 5처럼 유사도 항이 실제로 만드는 차이 $w_s\Delta_s$ 는 평균 0.014, 최대 0.036이다. 반면 선호 조건 하나의 일치 여부가 만드는 차이 $w_p/|S|$ 는 조건이 1개면 0.3, 2개면 0.15, 3개면 0.10이다. 한 자릿수가 차이 난다. 여기서 다음 성질이 나온다.

명제 1 (선호 우선 정렬) 같은 가점을 받는 두 후보 $d, d' \in \mathcal{F}_k(q)$ 에 대해 $w_s\Delta_s(q) < w_p/|S|$ 이면

$$p(q, d) > p(q, d') \Rightarrow \text{score}(q, d) > \text{score}(q, d')$$

증명 p 는 $1/|S|$ 단위로만 달라지므로 $p(q, d) - p(q, d') \geq 1/|S|$ 이다. 따라서 $\text{score}(q, d) - \text{score}(q, d') \geq w_p/|S| - w_s|s(q, d) - s(q, d')| \geq w_p/|S| - w_s\Delta_s(q) > 0$ 이다. $\square$

재랭킹은 (가점, 선호 일치율, 유사도) 순의 사전식 정렬에 가깝게 동작하고, 유사도는 선호 수준이 같은 후보 사이의 순서만 정한다. 이 성질에서 가점 크기에 대한 두 가지 조건을 얻는다.

따름정리 1 (연상 가점의 상한) 연상 가점이 명시한 선호 조건 하나를 뒤집지 않으려면

$$w_c < \frac{w_p}{|S|_{\max}} - w_s\Delta_s$$

이어야 한다. 평가 질의의 선호 조건은 최대 3개이므로 $w_c < 0.1 - 0.036 = 0.064$ 가 필요하다. 처음 설정했던 $w_c = 0.15$ 는 이를 어긴다. 실제로 "비 오는 날 얼큰한 국물 먹고 싶어"는 $S = \{\text{매운맛, 제공온도, 국물}\}$ 로 한 단계가 0.1인데, 비가 연상시킨 전(부침개)이 국물 조건 하나를 어겨 $p = 2/3$ 이면서도 가점 0.15를 받아 $p = 1$ 인 국물 요리를 앞질렀다. 비 오는 날 얼큰한 국물을 원한 사람에게 김치전을 먼저 보여 준 셈이다. 채택한 $w_c = 0.05$ 는 이 조건을 만족하면서도 $w_s\Delta_s$ 의 평균(0.014)보다는 커서, 선호 수준이 같은 후보 사이에서는 연상 메뉴를 앞둔다.

따름정리 2 (언급 가점의 의미) $w_m = w_p$ 이면 언급한 메뉴는 모든 선호 조건을 만족한 것과 같은 점수를 받는다. "샌드위치 가볍게"는 $S = \{\text{든든함}\}$ 하나라 $w_p/|S| = 0.3$ 인데, 이전 설정 $w_m = 0.15$ 에서는 든든함이 보통인

샌드위치(가점 0.15)가 가벼움인 죽(선호 0.3)을 이기지 못했다. 샌드위치를 말한 사람에게 죽을 추천한 것이다. $w_m = 0.3$ 에서는 둘이 같은 수준이 되고 유사도가 높은 샌드wich가 앞선다. 반대로 $w_m > w_p$ 이면 언급한 메뉴가 선호 조건을 전부 어겨도 올라오므로, "김밥이랑 국물"처럼 언급 메뉴가 주인공이 아닌 질의에서 손해가 커진다 (7.4절).

계산 예 명제 10이 실제로 어떻게 작동하는지 "비 오는 날 얼큰한 국물 먹고 싶어"로 따라가 보자. 설명을 위해 세 후보의 유사도를 모두 s 로 같다고 두면, 매운 국물 요리인 해장국은 $0.7s + 0.3 \cdot 1 = 0.7s + 0.3$ 을 받는다. 칼국수는 국물과 온도는 맞지만 매운맛 라벨이 맞지 않아 $p = 2/3$ 이고, 비가 연상한 메뉴라 가점 0.05를 받아 $0.7s + 0.2 + 0.05 = 0.7s + 0.25$ 가 된다. 김치전은 국물 조건을 어겨 역시 $p = 2/3$ 이고 가점을 받아 $0.7s + 0.25$ 이다. 실제 유사도 차이는 최대 0.036이므로 해장국이 두 메뉴보다 뒤로 밀리는 일은 없다. 칼국수와 김치전 사이의 순서는 유사도가 정한다.

5.7 중복 제거와 다양성 제어

같은 메뉴의 변형이 목록을 채우면 사용자에게 선택지가 사라진다. 그래서 두 메뉴 이름에서 괄호, 공백, 구두점, 사이즈나 도우 표기를 지운 정규화 키가 같으면 같은 메뉴의 변형으로 본다. 업체명이 없는 공공 데이터는 어절 단위 접두어 관계일 때만 변형으로 본다. "두부찌개"와 "두부찌개 바지락"은 변형이지만 "순대"와 "순대볶음 백순대"는 다른 메뉴다. 메뉴군 $\gamma(d)$ 는 대표식품명의 마지막 어절로 정의한다. "붕어 매운탕"과 "아귀 매운탕"은 같은 "매운탕" 메뉴군이다.

알고리즘 1 상위 K 개 선택

입력: 점수순으로 정렬된 후보 목록 L , 메뉴군 상한 $c = 2$, 상한 면제 메뉴군 집합 $E = \{\gamma(d) : \exists t \in M \cup C, \mu(d, t) = 1\}$

1. $R \leftarrow ()$, 모든 메뉴군의 선택 횟수 $n_\gamma \leftarrow 0$
2. L 의 각 후보 d 를 순서대로 보며 $|R| = K$ 가 되면 멈춤
 1. R 안에 d 의 변형이 있으면 건너뛴 (사유: 중복)
 2. $\gamma(d) \notin E$ 이고 $n_{\gamma(d)} \geq c$ 이면 건너뛴 (사유: 메뉴군 상한)
 3. 아니면 d 를 R 에 추가하고 $n_{\gamma(d)} \leftarrow n_{\gamma(d)} + 1$
3. R 과 건너뛴 후보의 사유를 반환

사용자가 직접 말한 메뉴군은 상한에서 면제한다. "국수 먹고 싶어"라고 한 사람에게 국수를 두 개만 보여 주는 것은 다양성이 아니라 요청 무시이기 때문이다.

5.8 검색 범위 확장

필수 조건이 까다로우면 상위 100개 안에 조건을 통과하는 후보가 몇 개 없을 수 있다. 이때 조건을 풀지 않고 검색 범위를 넓힌다. 그림 6은 전체 흐름이다.




그림 6 선택과 검색 범위 확장의 흐름. 회색 상자가 알고리즘 1이고, 두 마름모가 알고리즘 2의 3단계와 4단계에 해당한다. 오른쪽 고리는 결과가 모자랄 때 전체 후보까지, 왼쪽 고리는 선호를 모두 만족하는 후보가 모자랄 때 400개까지 넓힌다.

알고리즘 2 검색 범위 확장

1. $k \leftarrow 100$
2. $R \leftarrow \text{Select}(\text{sort}_{\text{score}} \mathcal{F}_k(q))$ (Select는 알고리즘 1)
3. $|R| < K$ 이고 $k < |\mathcal{D}|$ 이면 $k \leftarrow \min(2k, |\mathcal{D}|)$ 로 두고 2로 돌아감
4. $|S| > 0$ 이고 $\sum_{d \in R} 1[p(q, d) = 1] < K$ 이고 $k < 400$ 이면 $k \leftarrow \min(2k, 400)$ 로 두고 2로 돌아감
5. R 을 반환하되 $|R| < K$ 이면 상태를 shortage로 표시하고 사유를 기록

3단계는 결과 수를 채우기 위한 확장이라 전체 후보까지 넓힌다. 4단계는 선호를 모두 만족하는 후보를 더 찾기 위한 확장이며, 400개에서 멈춘다. 필수 조건은 어떤 경우에도 풀지 않으므로 반환 목록은 항상 H 를 만족한다. 순위 품질보다 조건 준수를 앞에 둔 설계 선택이며, 그 이유는 9장에서 다시 다룬다.

6. 실험 설정

6.1 질의 세트

평가 질의 40개를 유형별로 만들었다. 이 중 공공 데이터에 적합(2점) 메뉴가 0개에서 2개뿐인 4개("치킨 먹고 싶어", "튀김 말고 구운 치킨", "피자 먹고 싶는데 느끼하지 않은 걸로", "다이어트 중이라 가벼운 샐러드")는 데이터 공백 문제라 빼고 36개로 평가했다. 빈 입력과 모순 질의 2개("맵지 않은 매운 음식", "국물 없는 국물 요리")는 결과가 0건이어야 정답인 별도 사례로 확인했다.

유형	수	예
기본	12	"비 오는 날 얼큰한 국물 먹고 싶어", "든든한 밥 한 끼"
복합 조건	9	"안 맵고 국물 있는 면", "찜 요리 든든하게"
부정 표현	6	"튀김 아닌 걸로 가볍게", "뜨겁지 않은 음식"
맥락	4	"추운 날 뜨끈한 국밥", "야식으로 가벼운 거"
메뉴 언급	4	"샌드위치 가볍게", "피자 말고 버거"
판정 미확정	1	"안 매운 건 싫어"

조건 추출기는 36개 중 32개에서 선호나 필수 조건을 하나 이상 뽑았다(필수 포함 12개, 메뉴 언급 11개, 맥락 3개). 조건을 하나도 뽑지 못한 질의는 "단짠단짠한 음식", "비 오는 날 전 부쳐 먹고 싶다", "안 매운 건 싫어", "피자 말고 버거"의 4개다. 뒤의 두 질의에서는 메뉴 언급이나 메뉴 제외는 인식했다.

6.2 판정 세트

1,088개 메뉴를 36개 질의 전부에 대해 판정할 수는 없으므로 풀링을 썼다. 그림 7은 판정 세트를 만든 과정이다.




그림 7 판정 세트 구축 과정. 여러 설정의 상위 결과를 합쳐 풀을 만들고, 1차 판정과 교차 판정, 불일치 재판정을 거쳐 승인한다.

먼저 텍스트 A와 B, 단계별 구성, 메뉴군 상한과 가점 변형, cross-encoder 변형의 상위 5개를 모두 합쳐 (질의, 메뉴) 판정 풀을 만들었다. 1차 판정에서는 모델이 질의마다 따로 적은 판정 기준에 따라 2(적합), 1(부분 적합), 0(부적합)을 매겼다. 예를 들어 "비 오는 날 얼큰한 국물"의 기준은 "2는 매콤하고 뜨거운 국물 요리, 1은 국물 요리지만 맵지 않음, 0은 그 외"였다. 교차 판정에서는 다른 모델(Sonnet)이 기존 판정을 보지 않은 채 공공 데이터 971행을 다시 판정했다. 마지막으로 모호했던 판정 기준을 보강해 불일치 행을 다시 판정하고, 질의 단위로 승인 상태를 반영했다.

그림 3. 판정 교차 검증 (공공 데이터 971행)




그림 8 1차 판정과 교차 판정의 혼동 행렬.

두 판정의 일치도는 혼동 행렬 $O = (o_{ij})$ 와 주변 분포로 만든 기대 행렬 $E = (e_{ij})$, $e_{ij} = o_{i \cdot} o_{\cdot j} / N$ 으로 계산했다.

$$\kappa = \frac{p_o - p_e}{1 - p_e}, \quad p_o = \frac{1}{N} \sum_i o_{ii}, \quad p_e = \frac{1}{N^2} \sum_i o_{i \cdot} o_{\cdot i}$$

$$\kappa_w = 1 - \frac{\sum_{i,j} w_{ij} o_{ij}}{\sum_{i,j} w_{ij} e_{ij}}, \quad w_{ij} = (i - j)^2$$

그림 8에서 일치율은 89.4%(868/971), 단순 $\kappa = 0.836$, 이차 가중 $\kappa_w = 0.919$ 이다. 불일치 103건 중 99건은 2와 1, 또는 1과 0 사이의 한 칸 차이였고, 0과 2로 정반대인 경우는 4건뿐이었다. 다만 두 판정자가 같은 계열의 모델이라 높은 일치도가 곧 정확성을 뜻하지는 않는다. 최종 승인 판정은 906건(적합 440, 부분 적합 225, 부적합 241)이다.

6.3 지표

질의 q 에 대한 반환 목록의 i 번째 항목 적합도를 g_i , 그 질의에서 판정된 모든 적합도의 다중집합을 J_q 라 한다. 판정 풀에 없는 항목은 $g_i = 0$ 으로 두고, 그 비율을 미판정 비율로 따로 보고한다.

$$\text{P@}K = \frac{1}{K} \sum_{i=1}^K 1[g_i \geq 2]$$

$$\text{DCG@}K = \sum_{i=1}^K \frac{2^{g_i} - 1}{\log_2(i + 1)}, \quad \text{nDCG@}K = \frac{\text{DCG@}K}{\text{IDCG@}K}$$

IDCG@ K 는 J_q 를 내림차순으로 정렬한 이상적 목록의 DCG다. 반환 수가 K 보다 적어도 분모는 그대로 두어, 적게 반환한 만큼 점수가 깎이게 했다.

$$\text{RR} = \begin{cases} 1/\min\{i : g_i \geq 2\} & \exists i, g_i \geq 2 \\ 0 & \text{그 외} \end{cases}, \quad \text{MRR} = \frac{1}{|Q|} \sum_{q \in Q} \text{RR}_q$$

6.4 통계 검정

질의가 36개뿐이라 평균 차이만 보고 결론을 내리기는 위험하다. 두 설정 A, B의 차이는 질의별 차이 $\delta_q = m_B(q) - m_A(q)$ 로 대응 부트스트랩을 했다. 질의 집합 Q 에서 크기 $|Q|$ 의 표본을 복원 추출해 평균 $\bar{\delta}^{*(b)}$ 를 $B = 2,000$ 번 구하고, 이를 정렬한 순서 통계량으로

$$\text{CI}_{95\%} = \left[\bar{\delta}_{([0.025B])}^*, \bar{\delta}_{([0.975B])}^* \right]$$

를 구한다. 구간이 0을 포함하면 우연 범위로 본다.

6.5 하이퍼파라미터와 환경

항목	값
인코더	intfloat/multilingual-e5-base (768차원, mean pooling, L2 정규화, 최대 512 토큰)
초기 검색 수 k	100 (필수 부족 시 전체까지, 선호 부족 시 400까지 2배씩)
반환 수 K	5
가중치 w_s, w_p, w_m, w_c	0.7, 0.3, 0.3, 0.05
메뉴군 상한 c	2
부트스트랩	$B = 2,000$, seed 0
환경	Apple Silicon 노트북, Python 3.12, sentence-transformers 6.1, PyTorch 2.14

7. 결과

7.1 단계별 기여 (RQ1)




그림 9 구성 요소를 하나씩 더했을 때의 P@5, nDCG@5, MRR.

설정	P@5	nDCG@5	MRR	미판정	최종 대비 nDCG 차이 [95% CI]
임베딩만	0.433	0.509	0.537	2.8%	-0.369 [-0.495, -0.244]
+ 조건 필터	0.500	0.606	0.620	2.8%	-0.272 [-0.393, -0.156]
+ 선호 재랭킹, 중복 제어 ($w_m = w_c = 0.15$)	0.767	0.847	0.889	0%	-0.031 [-0.096, +0.011]
최종 ($w_m = 0.3, w_c = 0.05$)	0.789	0.878	0.938	0%	0
최종, 텍스트 A	0.794	0.858	0.870	0%	

그림 9와 표에서 조건 필터는 nDCG를 0.097, 선호 재랭킹과 중복 제어는 0.241 올렸다. 가장 큰 기여는 선호 재랭킹이다. 5.6절의 분석과 맞는 결과인데, 필터는 조건을 어기는 후보를 지울 뿐 남은 후보의 순서는 여전히 유사도에 맡기는 반면, 재랭킹은 선호 일치율로 순서 자체를 다시 정한다.

속성 토큰을 넣은 텍스트 B는 텍스트 A보다 nDCG가 0.020, MRR이 0.067 높았다. 라벨 정보를 필터와 재랭킹에만 쓰지 않고 임베딩에도 넣어 주는 편이 유리하다는 뜻이다. 가점 조정의 효과(+0.031)는 질의 2개에 몰려 있어 신뢰구간이 0을 포함한다. 효과가 없다는 뜻이라기보다, 그 효과를 확인하기에는 질의가 적다는 뜻으로 읽어야 한다.

7.2 질의 유형별 결과




그림 10 질의 유형별 nDCG@5. 회색은 임베딩만, 색은 최종 설정이다.

그림 10에서 항상 폭이 가장 큰 유형은 부정 표현이다(0.173에서 0.893). 임베딩이 부정 표현을 구분하지 못한다는 1.1절의 가정과 맞으며, 부정을 필수 조건으로 바꾸는 규칙이 이 유형의 핵심이다. 기본(0.386에서 0.855)과 맥락(0.562에서 0.919)도 크게 올랐다. 메뉴 언급(0.793에서 0.794)은 거의 변하지 않았는데, 메뉴 이름은 임베딩만으로도 잘 잡히는 데다 "김밥이랑 국물"에서의 손실과 "샌드위치 가볍게"에서의 유지가 섞였기 때문이다. 판정 미확정 질의 "안 매운 건 싫어"는 이중 부정을 처리하지 못해 오히려 떨어졌다(1.000에서 0.597).

7.3 질의별 결과




그림 11 질의별 nDCG@5. 회색 점은 임베딩만, 색 점은 최종 설정이다.

그림 11에서 36개 중 17개 질의가 nDCG 1.0을 받았다. 임베딩만으로 0점이던 질의 8개 중 7개는 0.89에서 1.0 사이로 올랐다. "바삭하고 기름진 음식", "튀김 아닌 걸로 가볍게", "매운 거 싫어"가 그 예다. 회색 점이 보이지 않는 질의는 두 설정의 점수가 같은 경우이며, 전체 수치는 부록 B에 있다.

7.4 가점 분리 (RQ2)

그림 7. 가점 조합별 nDCG@5




그림 12 연급 가점 w_m 과 연상 가점 w_c 격자에서의 nDCG@5.

그림 12는 (w_m, w_c) 격자에서의 nDCG@5다. $w_m = 0.3$ 일 때 $w_c = 0.15$ 에서는 0.878에서 0.867로 떨어지고, $w_c \leq 0.05$ 에서는 결과가 같다. 격자 밖에서 따로 켜 $w_c = 0.064$ 와 0.1도 0.878이었다. $w_c = 0.1$ 은 따름정리 1의 경계로, 전(부침개)의 점수가 국물 요리와 정확히 같아져 유사도가 순서를 정한다. 이 질의에서는 유사도가 더 높은 국물 요리가 앞서 역전이 일어나지 않았다. 역전은 "비 오는 날 얼큰한 국물"에서 칼국수(매운맛 불일치)와 김치전(국물 불일치)이 모두 $p = 2/3$ 으로 가점 0.15를 받아 $p = 1$ 인 해장국, 매운탕을 앞지른 $w_c = 0.15$ 에서만 나타났다.

w_m 은 $w_p = 0.3$ 과 같을 때 가장 좋았다. 0.5로 올리면 "김밥이랑 국물"에서 김밥이 국물 요리를 밀어내 전체가 0.862로 내려가고, $w_m = 0$ (연급 무시)은 0.835로 떨어진다. 연급 가점은 필요하지만 선호 조건을 넘어서는 안 된다는 따름정리 2의 예측과 같다. 이 격자는 평가 질의로 직접 고른 것이므로 최적값 자체에 큰 의미를 두기는 어렵다. 의미가 있는 것은 따름정리가 예측한 경계에서 실제로 성능이 바뀐다는 점이다.

7.5 cross-encoder 재정렬 (RQ3)




그림 13 cross-encoder 재정렬 실험 결과.

유사도 모델을 더 강한 것으로 바꾸면 나아질지 궁금했다. 필터를 통과한 후보의 $s(q, d)$ 를 bge-reranker-v2-m3의 관련도 $s_{CE}(q, d) \in [0, 1]$ 로 바꾸고 나머지 식은 그대로 두었다.

$$\text{score}_{CE}(q, d) = w_s \cdot s_{CE}(q, d) + w_p \cdot p(q, d) + b(q, d)$$

메뉴 텍스트는 라벨 나열, 이름만, 자연문장의 세 가지를 시험했다. CE가 새로 올린 항목 368건은 같은 기준으로 추가 판정해 미판정 0%에서 비교했다. 이 실험은 승인 전 판정과 당시 코드로 측정했으므로 수치를 7.1절과 직접 비교하지는 않는다.

CE 단독(0.582)은 e5 단독(0.502)보다 높았다. 그러나 조건 로직과 합친 가장 좋은 조합도 0.772로, e5 기반 파이프라인(0.812)보다 낮았다. 결과를 들여다보면 이유가 보인다. CE는 한국어 음식의 의미를 잘 모른다. "바삭하고 기름진 음식"에 떡볶이와 감자탕을, "상큼하고 시원한 음식"에 매운탕을 올렸다. 글자 표면에도 쉽게 끌려서 "무조건 안 매운"에 무국을, "김밥이랑 국물"에 김국을 올렸다. 메뉴를 직접 말한 질의("샌드위치 가볍게")에서만 강했다.

척도 문제도 있다. s_{CE} 는 $[0, 1]$ 전체에 퍼져 있어 명제 1의 조건 $w_s \Delta_s < w_p / |S|$ 가 깨진다. 그러면 CE의 잘못된 판단이 선호 조건을 이기고 순위를 흔든다. 범용 다국어 재정렬 모델은 조건 로직이 이미 잡는 것 이상을 더하지 못했으므로 채택하지 않았다.

7.6 대분류 우선 추천 (RQ3)

식품대분류를 먼저 고르고 그 안에서 메뉴를 추천하는 2단계 방식도 검토했다. 질의 q 의 적합 메뉴가 걸쳐 있는 대분류 수를

$$\nu(q) = |\{\text{대분류}(d) : g(q, d) = 2\}|$$

로 정의하면, 대분류 하나만 고르는 방식이 얻을 수 있는 적합 메뉴는 많아야 가장 큰 대분류의 몫이다.




그림 14 질의별로 적합 메뉴가 걸쳐 있는 대분류 수 $\nu(q)$.

그림 14에서 $\nu(q) \geq 2$ 인 질의가 36개 중 23개다. "맵지 않고 따뜻한 음식"은 $\nu = 8$ 이다. $\nu(q) = 1$ 인 13개 질의("짬 요리", "매콤한 볶음" 등)는 현재 방식도 이미 해당 대분류 안에서 추천하고 있다. 게다가 국밥이 밥류에, 떡국이 면 및 만두류에 들어 있는 것처럼 대분류 자체가 사용자의 음식 구분과 어긋난다. 대분류는 순위를 정하는 데보다 결과를 묶어 보여 주거나 사용자에게 되묻는 화면을 설계하는 데 쓰는 편이 맞다.

7.7 오류 분석

질의	nDCG@5	원인
국물 없는 매운 음식	0.333	필수 국물=없음은 지켰지만 매운지 모호한 쟁반국수, 막국수(모두 1점)가 상위를 차지하고 제육볶음 같은 매운 비국물 요리가 유사도에서 밀림
단짬단짬한 음식	0.390	"단짬"은 스키마에 없는 맛이라 미처리로 남아 임베딩에만 의존, 짬뽕과 매운탕이 올라옴
안 매운 건 싫어	0.597	매운 것을 원한다는 이중 부정이 미처리로 남아 매운탕 2개 외에 미음, 묵밥이 섞임
뜨겁지 않은 음식	0.672	필수 제공온도는 지켰지만 "따뜻함"으로 라벨된 전류(1점)가 차가운 음식을 밀어냄
김밥이랑 국물	0.799	뒤쪽(국물)이 주인공인데 김밥에 언급 가점이 붙어 김밥 2개가 섞임

점수가 낮은 질의의 원인은 세 가지로 모인다. 첫째는 스키마에 없는 속성이다. 단맛이나 신맛을 표현할 방법이 없으면 그 질의는 임베딩 단독 수준으로 돌아간다. 둘째는 조건 추출기가 처리하지 못하는 이중 부정과 메뉴 조합 표현이다. 셋째는 명제 1의 이면으로, 부분 적합 메뉴가 많은 조건에서는 같은 선호 수준 안의 순서를 유사도가 정하는데 유사도의 변별력이 약하다. "국물 없는 매운 음식"이 대표적인 예다.

7.8 실행 시간

질의 임베딩을 포함해(모델 로딩 제외) 질의당 평균 13 ms, 최대 16 ms가 걸렸다. 후보가 1,088건이라 전체 코사인 계산은 $O(|\mathcal{D}| \cdot 768)$ 로 무시할 만하고, 시간 대부분은 질의 인코딩에 쓰인다.

8. 서비스 연동과 피드백 학습 (RQ5)

추천 알고리즘을 웹 서비스(먹지)에 붙이면서 두 가지를 더했다. 하나는 사용자의 반응을 모아 바로 점수에 반영하는 피드백 재랭킹이고, 다른 하나는 쌓인 반응과 승인 판정으로 인코더 자체를 다시 학습하는 미세조정이다. 그림 15는 서비스 안에서 추천기와 이 두 경로가 연결되는 방식을 보여 준다.




그림 15 서비스 연동 구조. 첫째 줄과 둘째 줄은 메뉴 추천이 주변 음식점 목록으로 바뀌는 과정이고, 셋째 줄은 사용자 반응이 피드백 가점과 미세조정으로 되돌아가는 경로다. 미세조정 모델은 교체 기준을 통과할 때만 추천기에 반영된다.

8.1 음식점 연결

추천기는 메뉴를 고를 뿐 음식점은 고르지 않는다. 서비스는 다음 순서로 메뉴를 주변 음식점으로 바꾼다. 먼저 추천기가 상위 $3K$ 개 메뉴를 내고, 대표식품명이 같은 메뉴를 하나로 합쳐 검색어 K 개를 만든다. 검색어마다 카카오 로컬 키워드 검색으로 반경 안의 음식점(분류 FD6)을 최대 15곳 찾는다.

키워드 검색은 생각보다 느슨했다. "국밥"을 검색하면 중식당이 섞여 나왔다. 그래서 메뉴의 계열(한식, 중식, 일식, 양식)과 음식점 카테고리의 대분류가 서로 다른 나라 음식이면 뺀다. 그다음 카카오맵 가게 정보의 메뉴 목록에 검색어가 들어간 메뉴가 있는지 확인한다. 메뉴 목록이 있는데 검색어가 없으면 빼고, "라면사리"처럼 사리나 추가가 붙은 결들임은 인정하지 않는다. 남은 음식점의 일치도는 메뉴 점수와 거리로 매긴다.

$$\text{match}(r) = 100 \cdot \left(0.8 \cdot \frac{\text{score}(q, m_r)}{\max_m \text{score}(q, m)} + 0.2 \cdot \left(1 - \frac{\min(\delta_r, R)}{R} \right) \right)$$

m_r 은 음식점 r 을 찾게 한 메뉴, δ_r 은 거리, R 은 검색 반경이다. 메뉴를 확인한 음식점을 먼저, 그다음 일치도와 거리 순으로 보여 준다. "라면"을 성공회대 정문 반경 1km로 검색했을 때 메뉴 확인을 거친 11곳은 모두 메뉴에 라면(라면, 떡라면, 계란라면 등)이 있었다. 그중 갈빗집 한 곳은 "라면사리"만 있었고, 이 사례를 보고 결함 규칙을 더했다.

8.2 피드백 수집과 즉시 재랭킹

추천 결과 화면의 "결과에 만족하시나요?", 음식점 상세의 "이 추천이 잘 맞았나요?"와 "이걸로 골랐어요!"로 (질의, 메뉴 검색어, 좋아요 여부)를 모은다. 질의 q 를 공백으로 나눈 단어 집합을 $T(q)$, 단어 t 와 메뉴 m 에 대한 좋아요와 별로예요 수를 $L_{t,m}$, $D_{t,m}$ 이라 하면 피드백 가점은

$$f(q, m) = w_f \cdot \frac{1}{|T(q)|} \sum_{t \in T(q)} \frac{L_{t,m} - D_{t,m}}{L_{t,m} + D_{t,m} + \alpha}, \quad w_f = 0.15, \alpha = 2$$

이다. "이걸로 골랐어요"는 좋아요 두 번으로 센다. 질의 전체가 아니라 단어 단위로 세는 이유는 같은 뜻의 질의가 조금씩 다르게 들어오기 때문이다. "매운 국물"과 "매운 국물 요리"는 다른 문자열이지만 "매운"과 "국물"에 대한 반응은 공유된다.

사전값 α 때문에 반응이 적으면 가점이 작고, 가점의 절댓값은 항상 w_f 보다 작다. 가점은 추천기가 필수 조건과 중복 제어를 거쳐 낸 상위 $3K$ 개에만 더하므로, 필수 조건을 어기는 메뉴가 피드백으로 올라오는 일은 없다. w_f 는 언급 가점 $w_m = 0.3$ 의 절반이라 사용자가 이름을 말한 메뉴를 피드백만으로 밀어내지는 못한다. 그래도 반응이 한쪽으로 충분히 쌓이면 선호 조건 한 단계($w_p/|S| \geq 0.1$, $|S| \leq 3$)는 넘을 수 있다. 따름정리 1이 약한 신호에 요구한 상한보다 크게 둔 것은, 피드백이 그 질의와 메뉴에 대한 직접 증거이기 때문이다.

"면 요리"에 냉면 좋아요 5번과 라면 별로예요 4번을 넣자 순위가 라면(0.905), 국수(0.900), 냉면(0.889)에서 냉면(0.997), 국수(0.900), 라면(0.805)으로 바뀌었다.

8.3 미세조정 방법

학습 데이터는 승인 판정 중 적합도 2인 (질의, 메뉴) 쌍과, 좋아요가 별로예요보다 많은 (질의, 메뉴 검색어) 쌍이다. 메뉴 쪽 입력은 임베딩을 만들 때 쓴 텍스트 B 원문이다. 평가 질의는 MD5 해시를 3으로 나눈 나머지가 0이면 평가용으로 두고 학습에서 뺀다. 해시로 나누면 질의 목록이 늘어나도 기존 질의의 소속이 바뀌지 않는다. 판정이 있는 36개 질의 중 평가용은 10개, 학습용은 26개이며 학습 쌍은 295개다.

손실은 배치 안의 다른 메뉴를 오답으로 쓰는 MultipleNegativesRankingLoss(Henderson et al., 2017)다. 배치 크기를 B , 코사인 유사도를 sim , 온도를 $\tau = 0.05$ 라 하면

$$\mathcal{L} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(\text{sim}(q_i, d_i)/\tau)}{\sum_{j=1}^B \exp(\text{sim}(q_i, d_j)/\tau)}$$

이다. 판정 데이터는 질의 하나에 적합 메뉴가 평균 11개라, 같은 질의나 같은 메뉴가 한 배치에 두 번 들어가면 서로의 정답이 오답 자리에 놓인다. 그래서 배치마다 질의와 메뉴가 겹치지 않게 나누었다. 기본 모델(multilingual-e5-base)에서 시작해 $B = 16$, AdamW 학습률 2×10^{-5} 로 1에폭 학습하고, 후보 1,088개를 새 모델로 다시 인코딩한다. 노트북 CPU에서 학습, 재인코딩, 평가까지 한 번에 약 1분이 걸린다.

8.4 풀링 편향과 평가 지표

6.2절의 판정 풀은 기존 설정들의 상위 결과로 만들었으므로 기존 모델의 결과는 거의 모두 판정되어 있다. 미판정을 0점으로 두는 6.3절의 nDCG는 풀 밖의 메뉴를 내는 새 모델을 체계적으로 불리하게 만든다(Buckley & Voorhees, 2004). 실제로 기본 모델의 미판정 비율은 0%였지만 미세조정 모델은 32%(학습용), 23%(평가용)였다. 그래서 두 지표를 더 썼다.

condensed nDCG@5는 추천 상위 20개에서 미판정 항목을 지우고 남은 순서의 앞 5개로 nDCG를 잰다(Sakai, 2007). 정답 회수율@10은 임베딩 검색 상위 10개에 든 적합도 2 메뉴의 비율이며, 분모는 $\min(10, |\{d : g(q, d) = 2\}|)$ 이다. 모델 교체는 평가용 질의에서 condensed nDCG@5가 0.01 이상 오르고 정답 회수율@10이 떨어지지 않을 때만 한다.

8.5 결과




그림 16 기본 모델과 미세조정 모델의 학습용, 평가용 질의 성능.

평가용 질의 10개

모델	nDCG@5 (미판정 0점)	미판정	condensed nDCG@5	정답 회수율@10
기본 모델	0.932	0%	0.932	0.439
미세조정 시드 0	0.751	26%	0.916	0.388
미세조정 시드 1	0.696	22%	0.892	0.408
미세조정 시드 2	0.773	22%	0.927	0.419
미세조정 평균	0.740	23%	0.911	0.405
중복 허용 배치 시드 0	0.701	26%	0.917	0.388

학습용 질의 26개

모델	nDCG@5 (미판정 0점)	미판정	condensed nDCG@5	정답 회수율@10
기본 모델	0.857	0%	0.857	0.405
미세조정 시드 0	0.645	32%	0.882	0.528
미세조정 시드 1	0.596	36%	0.847	0.450
미세조정 시드 2	0.732	27%	0.915	0.576
미세조정 평균	0.658	32%	0.881	0.518
중복 허용 배치 시드 0	0.678	31%	0.889	0.538

그림 16에서 미세조정은 학습용 질의의 정답 회수율을 0.405에서 0.518로, condensed nDCG를 0.857에서 0.881로 올렸다. 그러나 평가용 질의에서는 회수율이 0.439에서 0.405로, condensed nDCG가 0.932에서 0.911로 오히려 낮아졌다. 시드 0 기준으로 평가용 질의의 차이는 condensed nDCG -0.016 [-0.092 , $+0.048$], 회수율 -0.051 [-0.171 , $+0.069$]로 둘 다 신뢰구간이 0을 포함한다. 학습에 쓴 질의의 정답을 외웠을 뿐 처음 보는 질의로는 일반화되지 않았다. 서로 다른 질의 26개는 문장과 메뉴의 관계를 새로 배우기에 너무 적다. 교체 기준에 따라 서비스는 기본 모델을 유지했다.

이 실험에서 가장 크게 배운 것은 지표에 관한 교훈이다. 미판정을 0점으로 둔 nDCG는 평가용에서 0.932에서 0.740으로 크게 떨어졌지만, 같은 모델의 condensed nDCG 차이는 -0.020 에 그쳤다. 하락의 대부분은 풀링 편향이었다. 이 지표만 봤다면 미세조정이 추천을 크게 망친다고 잘못 결론 내렸을 것이다. 실제로 개발 중 첫 실험에서는 이 하락을 배치 구성 탓으로 잘못 해석했다. 같은 시드로 비교해 보면 중복을 허용한 배치와 겹치지 않게 나눈 배치의 차이는 학습용 회수율 0.538 대 0.528, 평가용 0.388 대 0.388로, 이 규모에서는 측정되지 않았다. 배치 분리는 손실의 정의상 맞는 처리라 유지했지만 효과는 확인하지 못했다.

8.6 운영

피드백은 AI 서버의 SQLite 파일에 저장하고 도커 볼륨에 두어 재배포 후에도 남게 했다. 서버는 하루에 한 번 별도 프로세스로 미세조정 조건을 확인한다. 좋아요 쌍이 지난 시도보다 200개 이상 늘었을 때만 판정 쌍과 합쳐 기본 모델에서 다시 학습하고, 8.4절의 기준을 넘으면 새 모델과 후보 벡터로 교체해 다시 불러온다. 학습은 서비스 프로세스와 분리되어 있어 추천 응답을 막지 않는다. 교체된 모델이 있더라도 후보 목록이 바뀌어 벡터의 메뉴 순서가 맞지 않으면 서버는 기본 모델로 돌아간다.

9. 논의

9.1 조건 로직과 임베딩의 역할 분담

명제 1과 7.1절의 결과를 함께 보면, 이 시스템에서 임베딩은 순위를 정하는 주체라기보다 후보 100개를 고르는 1차 필터이자, 선호 수준이 같은 후보 사이의 동점을 푸는 수단이다. 순위의 큰 틀은 조건 추출과 라벨이 정한다. 그러므로 성능의 상한은 라벨 품질과 규칙 커버리지에 달려 있다. cross-encoder처럼 더 강한 유사도 모델로 바뀌도 효과가

없었던 것도, 미세조정이 평가용 질의에서 성과를 내지 못한 것도 같은 맥락에서 이해할 수 있다. 임베딩을 아무리 개선해도 그것이 순위에 미치는 몫 자체가 작다.

9.2 가중치를 정하는 원리

따름정리 1과 2는 평가 질의에 맞춰 격자 탐색을 하기 전에도 가중치를 정할 수 있는 원리를 준다. 연상처럼 약한 신호는 $w_p/|S|_{\max}$ 보다 작게, 사용자가 이름을 말한 메뉴처럼 강한 신호는 w_p 와 같게 두면 된다. 이 원리는 평가 질의에 덜 의존하므로 격자 탐색보다 과적합 위험이 작다. 피드백 가점 w_f 도 같은 틀에서 정했다. 직접 증거이므로 연상 가점보다는 크게, 사용자의 명시적 언급보다는 작게 두었다.

9.3 필수 조건을 풀지 않는 선택

제약 기반 추천에서는 보통 만족하는 항목이 없으면 제약을 완화한다. 본 연구는 필수 조건을 풀지 않고, 부족하면 사유와 함께 적게 반환했다. "맵지 않은"이라고 말한 사용자에게 매운 음식을 섞어 5개를 채우는 것보다 3개만 보여주는 편이 신뢰를 지킨다고 보았다. 이 선택의 비용은 nDCG에 그대로 드러난다. 반환 수가 적으면 분모가 그대로여서 점수가 깎이기 때문이다. 그럼에도 서비스 관점에서는 옳은 선택이라고 판단한다.

10. 한계

10.1 평가 질의 과적합

평가 질의 40개는 개발자가 직접 만들었다. 조건 추출 규칙, 가중치, 가점도 이 질의를 보면서 정했다. 따라서 0.878은 일반화 성능이 아니라 개발 세트 성능이며, 조정에 쓰지 않은 질의로 따로 측정해야 한다.

10.2 조건 추출 커버리지

규칙에 없는 표현은 조건 없이 임베딩만으로 처리되어 임베딩 단독 수준(nDCG 0.51)에 가까워진다. 실제 사용자의 표현은 평가 질의보다 훨씬 다양할 것이다. "속이 편한 거", "입이 심심해" 같은 표현은 지금의 규칙으로는 조건이 되지 않는다.

10.3 라벨과 판정의 신뢰도

음식 속성 라벨은 모두 모델 추정이며 사람이 표본을 검토해 정확도를 재지 않았다. 판정도 두 모델의 합의를 바탕으로 하고 사람이 모든 행을 직접 검토하지는 않았으므로, 두 모델이 공유하는 편향이 일치한 800여 행에 남아 있을 수 있다. 폴링 판정은 폴 밖의 좋은 메뉴를 놓칠 수 있어, 폴을 만든 설정과 다른 새 방법은 미판정 비율을 함께 봐야 한다.

10.4 데이터 공백

공공 데이터에는 실제로 자주 찾는 치킨, 피자, 샐러드, 버거가 거의 없다. 지금은 이런 요청에 관련 없는 메뉴를 추천하므로 "해당 메뉴 데이터 없음"을 알리는 처리가 필요하다.

10.5 표본 크기

질의 36개로는 신뢰구간이 넓어 nDCG 0.03 수준의 차이는 구분할 수 없다. 미세조정 평가용 질의는 10개뿐이라 8.5절의 결론도 방향만 보여 준다.

10.6 피드백 학습

로그인이 없어 한 사람이 같은 반응을 반복해서 보낼 수 있다. 가점 상한 w_f 와 미세조정 교체 기준이 피해를 제한할 뿐 막지는 못한다. 피드백 가점은 추천기가 낸 상위 3K개 안에서만 순서를 바꾸므로, 좋아요를 받았더라도 후보 밖의 메뉴를 끌어올리지는 못한다. 좋아요는 음식점까지 본 뒤의 반응이라 메뉴의 적합성과 음식점에 대한 만족이 섞여 있다. 음식점 메뉴 확인은 공개되지 않은 카카오맵 가게 정보를 쓰므로, 구조가 바뀌면 확인 없이 동작하도록 두었다.

11. 결론

본 연구는 규칙 기반 조건 추출과 속성 라벨 재랭킹을 밀집 검색에 더해 한국어 자연어 메뉴 추천의 nDCG@5를 0.509에서 0.878로 올렸다(RQ1). 향상은 임베딩이 가장 약한 부정 표현 질의에서 가장 컸다. 점수 척도를 분석해 재랭킹이 선호를 먼저 보는 사전식 정렬로 동작함을 보였고, 가점 크기의 상한 조건을 유도했으며, 실험에서 성능이 바뀐 지점은 그 경계와 맞았다(RQ2). 기성 cross-encoder는 한국어 음식 의미를 잘 모르고 점수 척도가 넓어 선호 조건을 흔들었고, 대분류 우선 추천은 정답이 여러 대분류에 흩어진 질의가 많아 맞지 않았다(RQ3). 판정 세트는 교차 판정 가중 $\kappa_w = 0.919$ 로 일관성이 높지만 같은 계열 모델의 합의라는 한계가 있다(RQ4). 판정 기반 미세조정은 학습한 질의에서만 나아지고 처음 보는 질의로는 일반화되지 않았으며, 기존 판정 풀은 새 모델을 체계적으로 불리하게 재므로 condensed nDCG와 정답 회수율로 따로 평가해야 했다(RQ5).

돌아보면 이 프로젝트에서 가장 효과가 컸던 작업은 더 좋은 모델을 찾는 일이 아니라, 사용자가 무엇을 원하지 않는지 정확히 알아듣는 일이었다. 앞으로의 과제를 우선순위 순으로 적으면 다음과 같다.

1. **보류 질의 평가**: 개발에 쓰지 않은 실제 사용자 질의 20개에서 30개로 일반화 성능을 잰다
2. **데이터 공백 응답**: 후보가 없는 메뉴 요청에는 데이터가 없다는 사실을 명시한다
3. **미처리 질의 기록**: 조건을 하나도 뽑지 못한 질의를 모아 규칙 확장의 순서를 정한다
4. **스키마 확장**: 단맛, 신맛, 짭맛, 고소함 축을 추가하고 다시 라벨링한다
5. **라벨 검증**: 속성 라벨 표본을 사람이 검토해 정확도를 재고, 든든함의 $\perp$ 비율(23%)을 줄인다
6. **미세조정 데이터 확보**: 서로 다른 실제 질의의 피드백을 수백 쌍 이상 모은 뒤 다시 학습하고, 판정 풀에 새 모델의 결과를 추가 판정해 미판정 비율을 낮춘다

참고문헌

- Buckley, C., & Voorhees, E. M. (2004). Retrieval evaluation with incomplete information. *Proceedings of SIGIR 2004*, 25-32.

- Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., & Liu, Z. (2024). *BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation*. arXiv:2402.03216.
- Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1), 37-46.
- Felfernig, A., & Burke, R. (2008). Constraint-based recommender systems: technologies and research issues. *Proceedings of ICEC 2008*.
- Henderson, M., Al-Rfou, R., Strope, B., Sung, Y., Lukács, L., Guo, R., Kumar, S., Miklos, B., & Kurzweil, R. (2017). *Efficient Natural Language Response Suggestion for Smart Reply*. arXiv:1705.00652.
- Järvelin, K., & Kekäläinen, J. (2002). Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, 20(4), 422-446.
- Nogueira, R., & Cho, K. (2019). *Passage Re-ranking with BERT*. arXiv:1901.04085.
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of EMNLP-IJCNLP 2019*, 3982-3992.
- Sakai, T. (2007). Alternatives to Bpref. *Proceedings of SIGIR 2007*, 71-78.
- Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., & Wei, F. (2024). *Multilingual E5 Text Embeddings: A Technical Report*. arXiv:2402.05672.
- 공공데이터포털, 식품 영양성분 데이터베이스. <https://www.data.go.kr>

부록 A. 재현 방법

```
source .venv/bin/activate
pytest                                # 단위 테스트 155개
python docs/make_figures.py           # 그림 3, 5, 8~14와 docs/figures/stats.json 재생성
python docs/finetune_experiment.py    # 그림 16과 docs/figures/finetune.json 재생성 (미세조정 5회, 약 5분)
python -m api.finetune --force        # 서비스와 같은 미세조정 한 번 실행, 교체 여부는 state/current.json
jupyter notebook notebooks/          # 01~07 단계별 실험
```

data/는 Git에서 제외되어 있어 원본 CSV와 임베딩, 판정 파일 (data/processed/evaluation/judgments.csv)이 따로 있어야 한다. 그림 13은 되돌린 실험의 기록값을 그린다. 본문의 모든 수치는 docs/figures/stats.json에 있다. 구조도(그림 1, 2, 4, 6, 7, 15)는 코드에서 생성하지 않는 설명용 그림이다.

부록 B. 질의별 nDCG@5

질의	유형	임베딩만	최종	차이
꼭 국물 요리로	복합	1.000	1.000	+0.000
너무 맵지 않은 국물 요리	복합	1.000	1.000	+0.000
느끼하지 않은 담백한 음식	기본	0.446	1.000	+0.554
든든한 밥 한 끼	기본	0.744	1.000	+0.256
따뜻하고 든든한 국밥	복합	0.869	1.000	+0.131
따뜻한 국이나 찌개	기본	1.000	1.000	+0.000
맵지 않고 따뜻한 음식	기본	0.903	1.000	+0.097
무조건 안 매운 걸로	부정	0.384	1.000	+0.616
바삭하고 기름진 음식	기본	0.000	1.000	+1.000
안 맵고 국물 있는 면	복합	0.333	1.000	+0.667
찜 요리 든든하게	복합	0.815	1.000	+0.185
차가운 국물 요리	복합	0.071	1.000	+0.929
차가운 면 요리	복합	0.640	1.000	+0.360
추운 날 뜨끈한 국밥	맥락	0.000	1.000	+1.000
튀김 아닌 걸로 가볍게	부정	0.000	1.000	+1.000
포만감 있는 저녁밥	기본	0.676	1.000	+0.324
해장되는 얼큰한 국	맥락	0.887	1.000	+0.113
빠르게 먹을 수 있는 간식	기본	0.000	0.935	+0.935
느끼한 거 말고 얼큰한 거	부정	0.604	0.912	+0.308
비 오는 날 얼큰한 국물 먹고 싶어	기본	0.431	0.912	+0.482
샌드위치 가볍게	메뉴 언급	0.912	0.912	+0.000
상큼하고 시원한 음식	기본	0.000	0.903	+0.903
야식으로 가벼운 거	맥락	0.589	0.903	+0.314
국물 없는 담백한 거	부정	0.000	0.887	+0.887
매운 거 싫어	부정	0.000	0.887	+0.887
김밥이랑 국물	메뉴 언급	0.799	0.799	+0.000
차갑고 가볍게 먹을 메뉴	기본	0.044	0.790	+0.746
비 오는 날 전 부쳐 먹고 싶다	맥락	0.774	0.774	+0.000
구운 고기 요리	복합	0.726	0.770	+0.044

질의	유형	임베딩만	최종	차이
떡볶이 매운 거	메뉴 언급	0.770	0.760	-0.010
매콤한 볶음 요리	복합	0.770	0.760	-0.010
피자 말고 버거	메뉴 언급	0.689	0.702	+0.013
뜨겁지 않은 음식	부정	0.049	0.672	+0.624
안 매운 건 싫어	미확정	1.000	0.597	-0.403
단짠단짠한 음식	기본	0.390	0.390	+0.000
국물 없는 매운 음식	기본	0.000	0.333	+0.333